Sprawozdanie - Analiza Wypożyczalni DVD

AGH

AGH UNIVERSITY OF KRAKOW

Łukasz Mamczura

Technologie Przemysłu 4.0

Rok III semestr V

Analiza Danych

1. Wstęp

Firma wynajmująca DVD zwróciła się o pomoc w przewidywaniu liczby dni, na które klient wypożyczy DVD. Celem analizy jest stworzenie modeli regresyjnych, które pomogą firmie w bardziej efektywnym planowaniu zapasów.

Dane dostarczone przez firmę znajdują się w pliku CSV "rental_info_egz.csv" i zawierają następujące cechy:

- "rental_date" - data i godzina wypożyczenia
- "return_date" - data i godzina zwrotu
- "amount" - kwota zapłacona za wypożyczenie
- "rental_rate" - stawka wypożyczenia
- "release_year" - rok wydania filmu
- "length" - długość filmu w minutach
- "replacement_cost" - koszt wymiany DVD
- "special_features" - dodatkowe funkcje DVD
- "NC-17", "PG", "PG-13", "R" - zmienne zero-jedynkowe dotyczące oceny filmu

Analiza przeprowadzona została zgodnie z metodologią TIER.

2. Analiza zysków na podstawie roku wydania filmu – Zadanie 1

2.1 Identyfikacja najbardziej dochodowych lat

Przeanalizowano dane pod kątem roku wydania filmu i jego dochodowości. Wyniki pokazują, że trzy najbardziej dochodowe lata to 2004, 2006, 2007. Przedstawiono to na wykresie.

2.2 Analiza ocen filmów w tych latach

Dla każdego z tych trzech lat przedstawiono rozkład ocen filmów (NC-17, PG, PG-13, R) na osobnych wykresach.

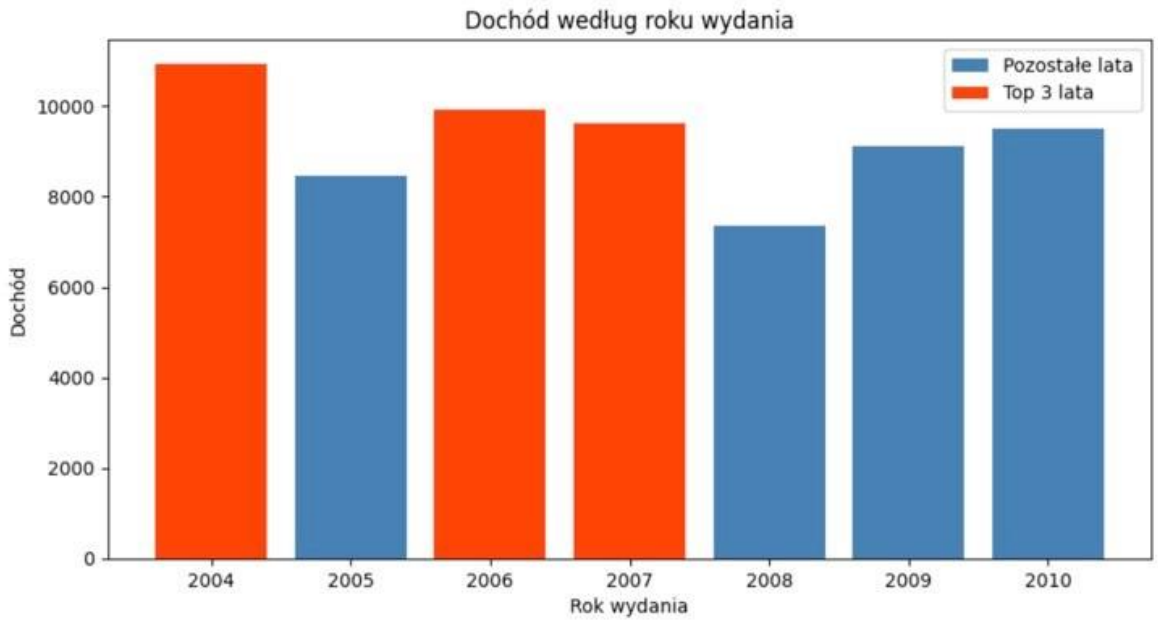

Rys. 1. Identyfikacja trzech najbardziej dochodowych lat

Dla tych trzech lat wykonane zostały wykresy rozkładu ocen filmów

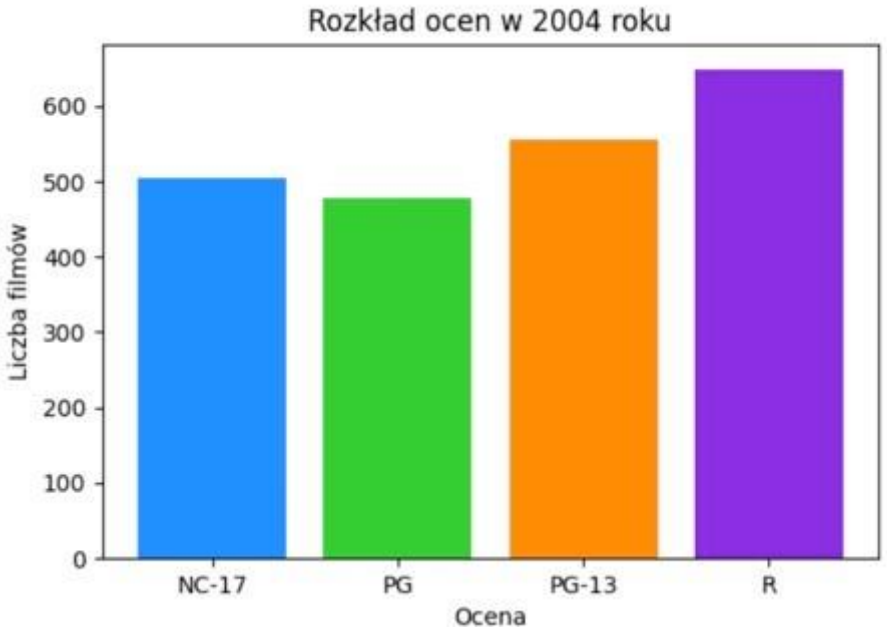

Rys. 2. Analiza rozkładu ocen filmów w 2004 roku

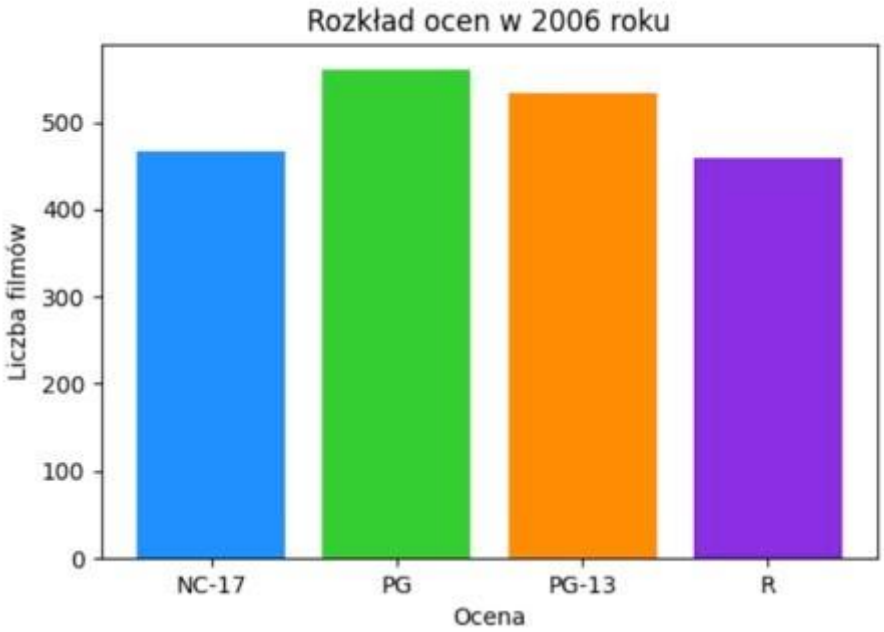

Rys. 3. Analiza rozkładu ocen filmów w 2006 roku ”

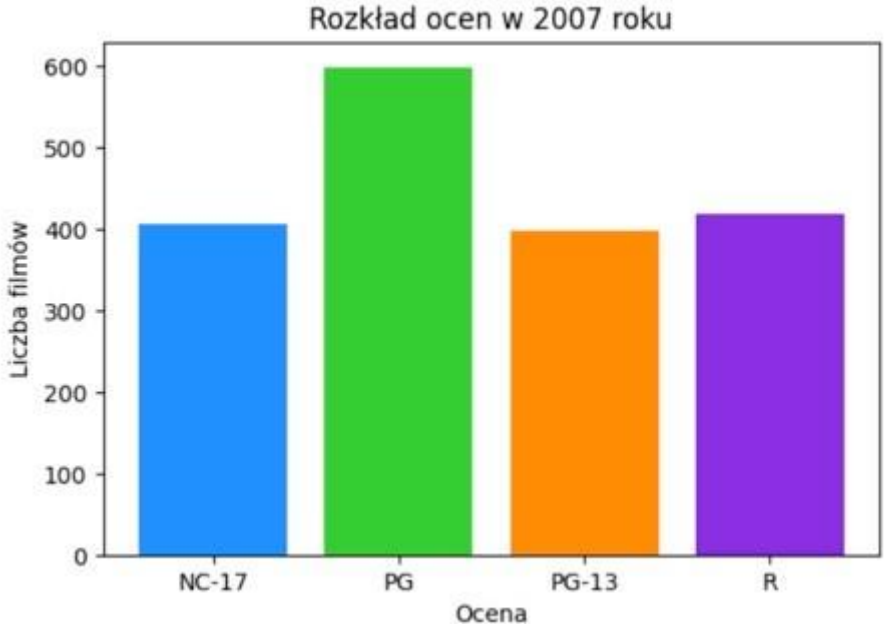

Rys. 4. Analiza rozkładu ocen filmów w 2007 roku

3. Tworzenie nowych cech – Zadanie 2

W celu poprawy modelowania stworzono nowe cechy:

1. Czas wypożyczenia (rental_days) - różnica między "return_date" a "rental_date".

2. Kody binarne dla special_features - zakodowano obecność zwiastunów i usuniętych scen**.**

4. Przetwarzanie danych - Zadanie 3

Skalowanie danych

Trzeci kod odpowiada za przetwarzanie danych przed modelowaniem. Obejmuje to normalizację zmiennych, wzbogacenie zbioru o dodatkowe cechy oraz ocenę, czy dane wymagają dalszej obróbki i oczyszczania.

Odpowiedzi na pytania:

1. Czy potrzebna jest standaryzacja danych?

Odpowiedź:
Konieczne było zastosowanie standaryzacji. Zbiór danych zawierał zmienne o różnych zakresach wartości, takie jak *rental_rate*, *rental_duration*, *length* czy *replacement_cost*. Bez odpowiedniego skalowania cechy o większych wartościach mogłyby nadmiernie wpływać na model, prowadząc do zniekształcenia wyników. W celu uniknięcia tego problemu wykorzystano standaryzację, która przekształciła dane tak, aby ich średnia wynosiła 0, a odchylenie standardowe było równe 1.

2. Czy należy usunąć niektóre wiersze?

Odpowiedź:
Wiersze zawierające brakujące wartości zostały usunięte. W tym celu wykorzystano metodę dropna(), która eliminuje wszystkie rekordy z pustymi komórkami. Decyzja ta była uzasadniona, ponieważ niekompletne dane mogły negatywnie wpłynąć na analizę oraz jakość modelowania, zwłaszcza gdy brakowało istotnych informacji, takich jak daty czy stawki wypożyczeń.

Które brakujące wartości można imputować?

Odpowiedź:
W niektórych przypadkach brakujące wartości mogłyby zostać uzupełnione, jednak tutaj zdecydowano się na ich usunięcie za pomocą metody dropna(). Gdyby imputacja okazała się konieczna, brakujące dane w zmiennych numerycznych mogłyby zostać zastąpione ich średnią. W tym projekcie uznano jednak, że brakujące informacje są zbyt istotne, aby je wiarygodnie uzupełnić, dlatego zdecydowano się na ich usunięcie.

Dokonano analizy zmiennych numerycznych i przeprowadzono standaryzację następujących cech:
rental_rate, rental_duration, rental_duration_sq, cost_per_minute, length, replacement_cost
Do skalowania danych zastosowano StandardScaler

Czyszczenie danych

Brakujące wartości zostały usunięte w sposób, który nie wpłynął negatywnie na jakość analizy
Zidentyfikowano zmienne wymagające imputacji i uzupełniono brakujące dane za pomocą wartości średniej

5. Modelowanie regresyjne - Zadanie 4

Skrypt odpowiada za tworzenie i ocenę modeli predykcyjnych. W pierwszym kroku wczytywane są dane przygotowane na wcześniejszych etapach, po czym określane są zmienne objaśniające oraz zmienna docelowa, reprezentująca kwotę zapłaconą za wypożyczenie DVD. Następnie dane dzielone są na zbiór treningowy i testowy w stosunku 70/30, co umożliwia trenowanie modeli na części danych i ich późniejszą ocenę.

Pierwszym zastosowanym modelem jest regresja liniowa, którą trenuje się na zbiorze uczącym, a następnie wykorzystuje do prognozowania wartości na danych testowych. Jakość modelu oceniana jest przy użyciu współczynnika determinacji R^2 oraz średniego błędu kwadratowego (MSE). Dodatkowo generowany jest wykres ukazujący zależność między rzeczywistymi a przewidywanymi wartościami kwoty wypożyczenia w odniesieniu do czasu trwania wypożyczenia.

W kolejnym etapie wdrażany jest model XGBoost, który opiera się na algorytmach drzew decyzyjnych i stanowi bardziej zaawansowaną metodę regresji. Podobnie jak w przypadku regresji liniowej, model jest trenowany na zbiorze uczącym, a jego skuteczność oceniana na danych testowych przy pomocy wskaźników R^2 i MSE. Wizualizacja wyników pozwala na lepsze porównanie efektywności obu podejść.

Na zakończenie przeprowadzana jest analiza porównawcza obu modeli pod kątem ich dokładności w przewidywaniu kwoty wypożyczenia. Wyniki są prezentowane w formie wartości R^2 i MSE, a wykresy zapisywane w folderze z wynikami. Skrypt umożliwia kompleksową ocenę skuteczności dwóch różnych technik regresji w analizie danych dotyczących wypożyczeń DVD.

Model regresji liniowej

Wykorzystano model regresji liniowej do estymacji wartości amount w oparciu o następujące zmienne rental_rate rental_duration rental_duration_sq cost_per_minute length replacement_cost
Dane zostały podzielone na zbiór treningowy i testowy w stosunku 70/30

Model XGBoost

Wykorzystano również model XGBoost, który został przetestowany na tych samych danych

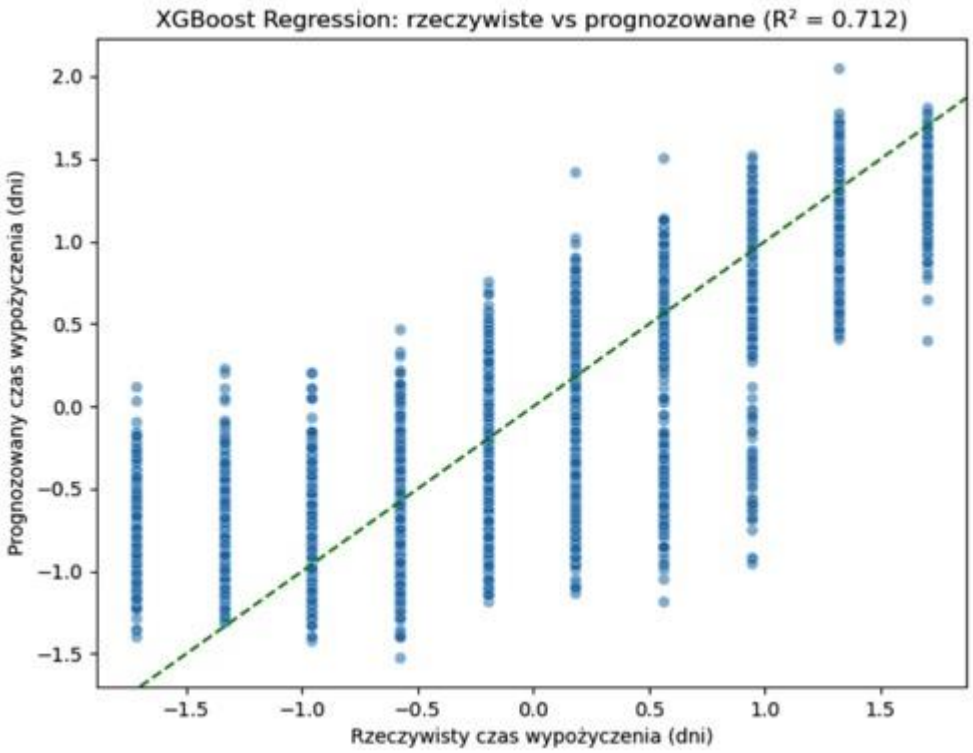

Rys. 5. Regresja liniowa

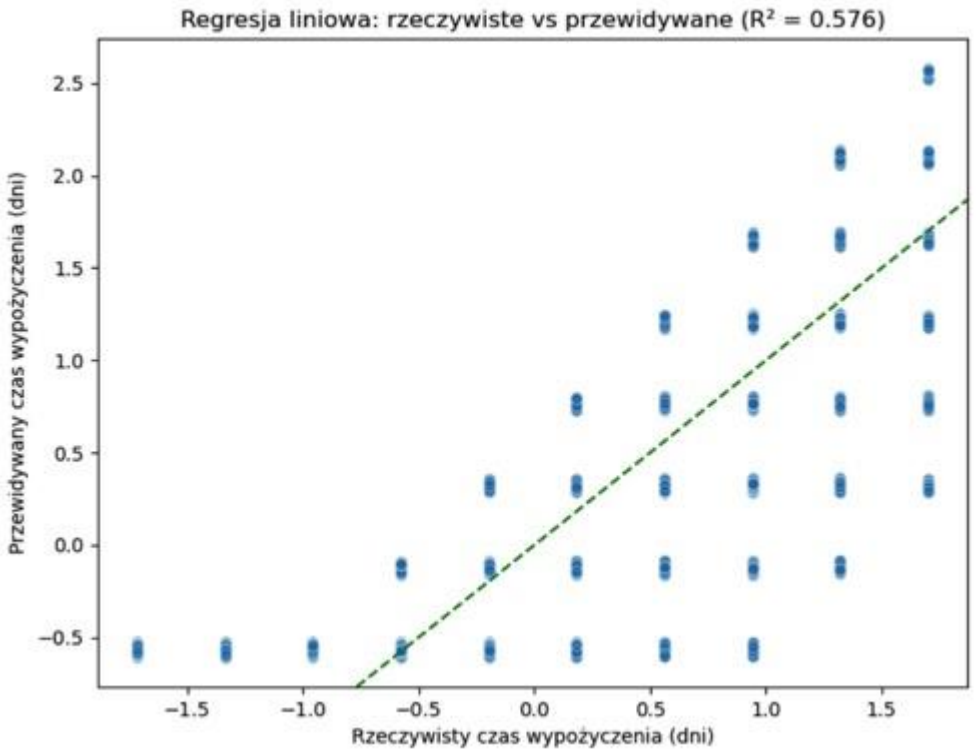

Rys. 6. Regresja XGBoost

6. Podsumowanie

Analiza miała na celu opracowanie modeli predykcyjnych wspomagających firmę wynajmującą DVD w prognozowaniu liczby dni wypożyczenia filmów. W tym celu wykorzystano dostarczony zbiór danych zawierający kluczowe informacje, takie jak daty wypożyczenia i zwrotu, kwoty zapłacone przez klientów, stawki wynajmu oraz dodatkowe cechy filmów.

Pierwszym etapem analizy była identyfikacja najbardziej dochodowych lat, w wyniku której wyodrębniono trzy lata generujące największe zyski: 2004, 2006 i 2007. Następnie przeprowadzono analizę rozkładu ocen filmów w tych latach, co pozwoliło na lepsze zrozumienie ich wpływu na rentowność wypożyczeń.

W celu poprawy jakości modeli regresyjnych utworzono nowe zmienne, m.in. czas wypożyczenia (rental_days) oraz zakodowane binarnie informacje o dodatkowych funkcjach DVD. Kolejnym krokiem było przetworzenie danych, w tym ich skalowanie oraz usunięcie brakujących wartości w sposób minimalizujący wpływ na analizę. Zmiennym numerycznym nadano jednolity zakres wartości poprzez standaryzację, co zwiększyło stabilność modeli predykcyjnych.

W ramach modelowania zastosowano dwa podejścia: regresję liniową oraz XGBoost. Oba modele były trenowane na zbiorze uczącym i oceniane na zbiorze testowym pod kątem skuteczności prognozowania kwoty wypożyczenia DVD.

Wyniki analizy oraz wizualizacje zapisano w katalogu wynikowym, umożliwiając dalszą interpretację i wykorzystanie modeli do optymalizacji zarządzania zapasami DVD.